



LLM Atlas

从预测模型 到行动系统

大模型从哪里来、当下处于什么阶段、未来要去往何处

2026-09 · 开源知识地图精炼版

阅读说明

本书是一张导航图，不是穷尽所有论文的百科。每章末尾的蓝色链接会跳转到 GitHub 知识库中的扩展页面；知识库保留 21 个章节、159 个主题页面、结构化目录和 Archify 交互地图。

目录

- 01 一张地图，而不是一串名词
- 02 从规则到 Transformer
- 03 数据、表示与架构
- 04 预训练与后训练
- 05 推理、评测与服务
- 06 上下文、RAG 与 Agent
- 07 多模态能力与系统安全
- 08 生产、基础设施与生态
- 09 2026：从生成模型到行动系统
- 10 下一站：多条未来同时展开

01 一张地图，而不是一串名词

大模型常被压缩成参数量、排行榜和产品名称，但这些只描述表面。真正的技术对象是一套生命周期：数据进入训练系统，形成可预测下一个 token 的模型；后训练把预测器塑造成助手；评测和安全门决定能否发布；推理、检索、工具与 Agent 把权重连接到动态世界；部署后的反馈又改变下一轮数据和目标。

三个问题

- ****从哪里来****：符号 AI、统计学习、神经表示、注意力和规模化如何汇合。
- ****当下在哪里****：模型已从内容生成走向推理、多模态和行动，但可靠性仍呈锯齿状。
- ****未来去哪里****：持续学习、长时 Agent、世界模型和 AI for Science 是否能跨越当前边界。

理解这张地图的关键，是区分模型能力与系统能力。检索、工具、验证器、上下文和权限可以让同一模型表现完全不同；它们也会引入新的攻击面。评估任何“突破”时，都应问：是权重变强、推理预算增加、工具更好，还是评测规则改变？

扩展阅读：[知识库入口](#) · [完整生命周期](#)

02 从规则到 Transformer

早期 AI 希望用显式符号和规则表示世界。它清晰、可组合，却难以覆盖开放世界。统计 NLP 把语言转为概率估计，神经网络进一步把特征本身交给数据学习。词向量证明语义可以形成连续几何；Seq2Seq 与注意力让模型根据当前需要读取输入。

2017 年提出的 Transformer 把注意力变成主要计算原语。它用多头注意力、前馈层、残差和归一化构建深层序列模型，训练可高度并行。大规模语料、加速硬件、稳定优化与分布式系统共同把它推向基础模型。

规模化的含义

经验规模定律使团队能预估参数、数据和计算增长对损失的影响。后来研究强调计算最优配比：模型不是越大越好，必须有足够数据训练。规模化还带来一个重要变化——模型不再只完成单任务，而是通过上下文和少量示例表现出跨任务迁移。

然而，平均预测损失下降不保证事实、推理和安全同步提高。基础模型的广泛先验需要后训练、工具和验证系统才能变成可靠产品。

扩展阅读：[历史源流](#) · [Transformer](#) · [规模定律](#)

03 数据、表示与架构

模型能学到什么，首先由数据决定。数据工程包括来源与许可、采集解析、清洗去重、质量分类、混合配比、污染检测、隐私处理与血缘。公开可访问不等于可以任意训练；高质量也不是一个分类器分数，而是事实、信息密度、多样性、领域覆盖与风险的组合。

Tokenizer 把输入切成 token。不同语言、代码和数字的分词效率不同，直接影响上下文容量和成本。嵌入把 token 映射到连续空间，位置机制则把顺序注入注意力。

架构不是孤立指标

Decoder-only Transformer 以统一生成接口成为主流；MoE 让每个 token 只激活少量专家；GQA/MQA 减小 KV cache；状态空间与混合模型探索更低长序列成本；多模态连接器把视觉、语音和视频接入模型。

判断新架构不能只看参数或理论复杂度。训练稳定性、通信、内核、批量、延迟、生态和真实任务共同决定它是否更好。“支持超长上下文”也只说明容量，不证明模型能稳定利用每个位置。

扩展阅读：[数据](#) · [表示](#) · [模型架构](#)

04 预训练与后训练

预训练通常用自监督 next-token 目标学习广泛分布。它要求数据流水线、混合精度、优化器、学习率、分布式并行、检查点与故障恢复协同工作。一次大训练中，坏数据、数值溢出、通信错误和硬件故障都会改变轨迹。

后训练决定模型如何面对用户。SFT 用示范学习任务与格式；偏好学习表达帮助性、风格和安全选择；RLHF/RLAIF 用奖励模型或规则优化序列行为；DPO 类方法直接学习偏好概率；验证器和可执行环境为数学、代码等任务提供更清晰信号。

奖励不是目标本身

任何奖励都只是人类意图的代理。模型会寻找捷径，因此需要独立评测、约束、对抗测试和人工责任。推理强化学习可以让模型学会分配更长思考、搜索与纠错，但可验证任务上的收益不自动迁移到开放世界。

蒸馏和领域适配用于降低成本或迁移能力。面对频繁变化的知识，更新检索库通常比反复写入权重更透明、更易回滚。

扩展阅读：[预训练](#) · [后训练](#)

05 推理、评测与服务

模型在训练结束后仍可通过推理时计算提高结果：更长思考、并行采样、搜索、工具和验证器都能增加成功率。这使能力成为按请求分配的动态预算，但也带来延迟与成本。可读思维链并不保证内部过程忠实，关键结论仍需外部证据或执行验证。

评测必须说明任务、提示、采样预算、上下文、工具权限、评审器和成本。公开基准容易污染与饱和，平均分会掩盖长尾。成熟 EvalOps 保存版本、置信区间、失败分类和发布门，并把生产事故转为回归测试。

把权重变成服务

推理系统使用 KV cache、连续批处理、量化、并行、投机解码和路由满足 SLA。首 token 延迟、每 token 延迟、吞吐、显存和成本相互制约。离线最高分模型未必是单位任务价值最优模型。

生产优化应基于真实输入/输出长度、并发和重试分布。任务成功一次的总成本，还应包含检索、工具、人工返工与失败影响。

扩展阅读：[推理时计算](#) · [评测](#) · [推理效率](#)

06 上下文、RAG 与 Agent

上下文工程决定一次推理能看到什么：系统指令、用户请求、检索证据、记忆、工具结果和环境状态。它要求最小充分内容、来源隔离、明确优先级、过期检测和失败降级，而不是寻找一句万能提示词。

RAG 把动态或私有知识放入上下文。完整链路包含解析、分块、索引、查询改写、检索、重排、组装、生成和引用验证。引用存在不等于主张得到支持；检索召回与模型使用证据的能力需要分别评估。

从回答到行动

Agent 在观察、计划、调用工具、读取结果与验证之间形成闭环。工具 schema 只约束格式，不保证语义正确或授权合理。执行层需要参数校验、最小权限、幂等、审计和不可逆动作前的人工确认。

长时 Agent 还需要持久状态、检查点、预算、取消与恢复。多 Agent 只有在任务可分解、结果可合并时才值得引入，否则只会增加通信与相关错误。

扩展阅读：[上下文与知识](#) · [Agent 与工具](#)

07 多模态能力与系统安全

多模态模型连接文本、图像、语音、视频和动作。它们从识别与生成走向实时对话、时空理解与环境行动。统一接口很吸引人，但不同模态的数据密度、带宽、误差和风险完全不同。

当模型可以行动，安全焦点从“说了什么”扩展为“能访问什么、能改变什么”。提示注入会把网页、邮件或文档中的不可信内容伪装成指令；供应链攻击可能污染数据、权重、依赖或检索库；记忆会固化错误与敏感信息。

分层防御

- 模型层：安全训练、校准和能力评测；
- 上下文层：来源隔离、内容与指令分离；
- 工具层：最小权限、参数验证、沙箱和审批；
- 运行层：监控、速率、日志、回滚和事件响应；
- 组织层：责任、升级阈值和停止条件。

系统提示不是权限边界，单一拒答率也不是安全证明。高风险系统需要异构监控与人工责任。

扩展阅读：[多模态](#) · [安全、Security 与隐私](#)

08 生产、基础设施与生态

上线不是终点，而是模型第一次接触真实分布。生产系统需要影子流量、灰度、版本固定、观测、反馈、路由、降级和回滚。模型、提示、工具、索引与策略应作为一个版本单元管理。

大模型基础设施受加速器、HBM、互连、网络、存储、电力与供应链约束。理论 FLOPS 不等于真实性能，数据移动、通信和内核成熟度常决定速度。训练是前期投入，推理成本随使用增长，长期高流量产品可能更重视小模型、量化、缓存和路由。

生态选择

闭源 API 提供托管和前沿能力；开放权重提供部署控制与本地适配。选择应比较质量、总成本、延迟、数据驻留、许可、锁定、更新稳定和团队运维能力。

领域应用的风险随“建议”到“执行”的权限上升。真正价值来自任务重构与责任设计，而不是把聊天界面覆盖到所有流程。

扩展阅读：[生产生命周期](#) · [基础设施与经济](#) · [生态与应用](#)

09 2026：从生成模型到行动系统

截至 2026 年 9 月，前沿竞争已从静态问答扩展到复杂推理、软件工程、多模态实时交互、工具/计算机使用、长任务、成本和安全。越来越多能力来自“模型 + 工具 + 推理预算 + 环境”，因此只报模型名称已不足以描述系统。

模型能在高难数学、科学和代码任务上表现突出，却仍可能在简单事实、感知、权限和长时一致性上失败。这种锯齿状能力意味着“超过人类基线”的局部结论不能推广为通用可靠性。

阶段判断

我们正处在从内容生成器转向推理与行动系统的过渡期。Agent 在受控数字环境中显著进步，但开放式长期自治仍会累积错误并需要人工介入。多模态正在统一，物理世界部署却受安全与数据约束。

能力进步也快于评测和治理。公开基准快速饱和，安全、透明度和生产事件的报告口径仍不统一。当前最重要的工程工作，是把能力增长转化为可测、可控、可恢复的系统。

扩展阅读：[2026-09 领域现状](#) · [证据仪表板](#)

10 下一站：多条未来同时展开

规模化不会突然停止，但未来收益更依赖高质量数据、稀疏/模块化架构、推理时计算和硬件协同。可验证合成数据与环境交互会补充人类数据，持续学习则可能形成稳定基座、适配器、外部知识和任务状态的多层更新体系。

长时 Agent 将承担更复杂的数字工作，但关键指标不是运行多久，而是在预算和权限内稳定完成、正确求助并可从中断恢复。世界模型与具身系统可能连接互联网语义、模拟和机器人控制；科学系统则会连接文献、代码、仪器与实验。

不应回避的不确定性

未来可能是渐进增强、Agent 跃迁、科学/物理突破或受资本与监管约束的平台化，也可能在不同领域同时发生。预测需要可观测前兆和明确证据等级。

无论能力路径如何，可靠评测、最小权限、来源溯源、运行监控、可逆操作和组织责任都不会过时。真正成熟的智能系统不是从不犯错，而是知道何时停下、何时求助，并让错误后果受控。

扩展阅读：[未来前沿](#) · [参考手册](#)

继续探索

github.com/fomos-openai/llm-atlas

仓库包含 Archify 交互知识地图、全部主题页、模型/数据/基准/工具目录、引用政策与可复现构建脚本。内容采用日期快照和证据等级持续维护。

知识应该能被追溯、质疑、更新，也应该帮助我们知道何时停止自动化并寻求人类判断。