

LLM Atlas v2

从模型 到行动系统

完整生命周期 · 学术与产业圣杯 · Top 模型路线
可复现实践 · 技术专家成长路径

2026-10 · 开源工程知识地图

如何阅读

本书提供连续叙事，仓库提供可独立更新的深层知识。蓝色链接指向对应主题页；模型、框架和现状信息带核验日期。建议先完整阅读，再按工作问题回到知识树和实验。

目录

- 01 一张全景图：从模型到行动系统
- 02 从哪里来：七次约束解除
- 03 圣杯：学术目标与产业竞争
- 04 成熟技术流派与公开案例
- 05 目标、数据与 Tokenizer
- 06 架构与训练系统
- 07 预训练与能力塑形
- 08 后训练、推理与自我改进
- 09 评测、压缩、推理服务与发布
- 10 上下文、RAG、记忆与 Agent
- 11 小模型实践：从零训练到验证闭环
- 12 生产工程与 2026-10 状态
- 13 职业迁移：研发到大模型专家
- 14 未来：情景、信号与不确定性

01 一张全景图：从模型到行动系统

这本书首先建立共同坐标系：大模型不是孤立权重，而是由数据、计算、反馈、检索、工具、权限和运行系统组成的生命周期。

历史不是模型名称的年表，而是表示学习、可扩展优化、硬件和数据工程共同解除约束的过程。阅读本章时要问：当时真正的瓶颈是什么，新方法改变了哪个约束，又引入了什么新债务。

完整生命周期

从问题定义、数据、训练、后训练、评测、发布、运行反馈直到更新与退役建立闭环。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

先画清边界和反馈环，再进入局部技术。一个节点至少要说明输入、输出、所有者、持久状态与失败去向；一条路线至少要说明先修知识和可交付成果。

- 决策：在采用“完整生命周期”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [完整生命周期](#)。

五条知识主线

解释五条主线各自解决的问题、交叉点和推荐阅读顺序。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

先画清边界和反馈环，再进入局部技术。一个节点至少要说明输入、输出、所有者、持久状态与失败去向；一条路线至少要说明先修知识和可交付成果。

- 决策：在采用“五条知识主线”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [五条知识主线](#)。

角色化学习路线

为前端、后端、平台、模型和技术负责人提供不同入口与共同能力门槛。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

先画清边界和反馈环，再进入局部技术。一个节点至少要说明输入、输出、所有者、持久状态与失败去向；一条路线至少要说明先修知识和可交付成果。

- 决策：在采用“角色化学习路线”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [角色化学习路线](#)。

前置知识地图

把数学、深度学习、分布式系统、数据工程和产品安全映射到具体章节。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

先画清边界和反馈环，再进入局部技术。一个节点至少要说明输入、输出、所有者、持久状态与失败去向；一条路线至少要说明先修知识和可交付成果。

- 决策：在采用“前置知识地图”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [前置知识地图](#)。

证据与时效规则

规定稳定知识、时效快照、厂商自报、第三方复现和推演内容的标记方式。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

先画清边界和反馈环，再进入局部技术。一个节点至少要说明输入、输出、所有者、持久状态与失败去向；一条路线至少要说明先修知识和可交付成果。

- 决策：在采用“证据与时效规则”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [证据与时效规则](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

02 从哪里来：七次约束解除

技术史的价值在于解释为什么今天的系统长成这样，以及哪些旧问题只是换了形式再次出现。

历史不是模型名称的年表，而是表示学习、可扩展优化、硬件和数据工程共同解除约束的过程。阅读本章时要问：当时真正的瓶颈是什么，新方法改变了哪个约束，又引入了什么新债务。

符号、统计与神经方法

比较手写规则、概率模型与端到端表示学习的假设和边界。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

判断历史突破要看它解除的是表示、优化、并行、数据还是交互约束。新范式通常不会消灭旧问题，只会把瓶颈迁移到新的层级。

- 决策：在采用“符号、统计与神经方法”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [符号、统计与神经方法](#)。

表示学习、Seq2Seq 与注意力

解释分布式表示、编码器解码器和注意力如何解决长距离依赖与对齐。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

判断历史突破要看它解除的是表示、优化、并行、数据还是交互约束。新范式通常不会消灭旧问题，只会把瓶颈迁移到新的层级。

- 决策：在采用“表示学习、Seq2Seq 与注意力”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [表示学习、Seq2Seq 与注意力](#)。

Transformer 与自监督

从注意力、残差、归一化和自监督目标解释可并行扩展的基础。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

判断历史突破要看它解除的是表示、优化、并行、数据还是交互约束。新范式通常不会消灭旧问题，只会把瓶颈迁移到新的层级。

- 决策：在采用“Transformer 与自监督”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [Transformer 与自监督](#)。

预训练、规模化与上下文学习

连接经验规模定律、计算最优训练和少样本上下文能力。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

判断历史突破要看它解除的是表示、优化、并行、数据还是交互约束。新范式通常不会消灭旧问题，只会把瓶颈迁移到新的层级。

- 决策：在采用“预训练、规模化与上下文学习”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [预训练、规模化与上下文学习](#)。

指令化、对齐与对话模型

解释 SFT、偏好反馈和安全约束如何把基础模型变为可交互助手。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

判断历史突破要看它解除的是表示、优化、并行、数据还是交互约束。新范式通常不会消灭旧问题，只会把瓶颈迁移到新的层级。

- 决策：在采用“指令化、对齐与对话模型”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [指令化、对齐与对话模型](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

推理、Agent 与多模态

梳理推理时计算、工具环境和跨模态表示如何把生成器变为行动系统。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

判断历史突破要看它解除的是表示、优化、并行、数据还是交互约束。新范式通常不会消灭旧问题，只会把瓶颈迁移到新的层级。

- 决策：在采用“推理、Agent 与多模态”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [推理、Agent 与多模态](#)。

算力、数据与开放生态

分析加速器、公开权重、训练框架和社区复现对扩散速度的作用。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

判断历史突破要看它解除的是表示、优化、并行、数据还是交互约束。新范式通常不会消灭旧问题，只会把瓶颈迁移到新的层级。

- 决策：在采用“算力、数据与开放生态”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [算力、数据与开放生态](#)。

关键技术时间线

以问题、突破、证据和遗留问题四列记录关键节点。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

判断历史突破要看它解除的是表示、优化、并行、数据还是交互约束。新范式通常不会消灭旧问题，只会把瓶颈迁移到新的层级。

- 决策：在采用“关键技术时间线”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [关键技术时间线](#)。

03 圣杯：学术目标与产业竞争

圣杯把长期方向变成可观测的工程问题：目标是什么、代理指标是什么、什么证据足以宣布进展。

圣杯不是营销口号，而是长期目标、可观测代理指标和未解决瓶颈的组合。任何宣称突破的方案都必须说明任务分布、资源预算、失败率和是否存在独立复现。

圣杯成熟度矩阵

统一比较每个圣杯的证据等级、技术路线、可测指标与最大未知。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

圣杯必须拆成能力定义、代理指标、资源预算和反证条件。若一个进展只能在封闭基准或无限预算下成立，它尚未跨越工程门槛。

- 决策：在采用“圣杯成熟度矩阵”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [圣杯成熟度矩阵](#)。

泛化与可靠推理

研究模型能否跨分布组合知识、校准不确定性并给出可验证结论。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

圣杯必须拆成能力定义、代理指标、资源预算和反证条件。若一个进展只能在封闭基准或无限预算下成立，它尚未跨越工程门槛。

- 决策：在采用“泛化与可靠推理”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [泛化与可靠推理](#)。

样本与数据效率

研究如何用更少、更好、更有课程结构的数据获得同等能力。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

圣杯必须拆成能力定义、代理指标、资源预算和反证条件。若一个进展只能在封闭基准或无限预算下成立，它尚未跨越工程门槛。

- 决策：在采用“样本与数据效率”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [样本与数据效率](#)。

长期记忆与持续学习

研究不遗忘、可追溯且能在线吸收新知识的模型与系统。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

圣杯必须拆成能力定义、代理指标、资源预算和反证条件。若一个进展只能在封闭基准或无限预算下成立，它尚未跨越工程门槛。

- 决策：在采用“长期记忆与持续学习”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [长期记忆与持续学习](#)。

递归自我改进

区分合成数据闭环、自动研究、工具增强和真正权重级自改进。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

圣杯必须拆成能力定义、代理指标、资源预算和反证条件。若一个进展只能在封闭基准或无限预算下成立，它尚未跨越工程门槛。

- 决策：在采用“递归自我改进”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [递归自我改进](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

世界模型与具身智能

研究预测、规划、因果理解和物理交互如何形成闭环。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

圣杯必须拆成能力定义、代理指标、资源预算和反证条件。若一个进展只能在封闭基准或无限预算下成立，它尚未跨越工程门槛。

- 决策：在采用“世界模型与具身智能”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [世界模型与具身智能](#)。

可解释、对齐与控制

研究如何理解内部机制、表达规范并控制高能力系统。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

圣杯必须拆成能力定义、代理指标、资源预算和反证条件。若一个进展只能在封闭基准或无限预算下成立，它尚未跨越工程门槛。

- 决策：在采用“可解释、对齐与控制”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [可解释、对齐与控制](#)。

AI for Science

研究模型在可验证科学环境中提出假设、调用工具并产生新知识。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

圣杯必须拆成能力定义、代理指标、资源预算和反证条件。若一个进展只能在封闭基准或无限预算下成立，它尚未跨越工程门槛。

- 决策：在采用“AI for Science”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [AI for Science](#)。

单位成本智能

把任务成功率、延迟、吞吐、能源和总拥有成本放进同一优化目标。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

圣杯必须拆成能力定义、代理指标、资源预算和反证条件。若一个进展只能在封闭基准或无限预算下成立，它尚未跨越工程门槛。

- 决策：在采用“单位成本智能”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [单位成本智能](#)。

可靠自治 Agent

关注长任务成功率、错误恢复、权限和人工接管成本。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

圣杯必须拆成能力定义、代理指标、资源预算和反证条件。若一个进展只能在封闭基准或无限预算下成立，它尚未跨越工程门槛。

- 决策：在采用“可靠自治 Agent”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [可靠自治 Agent](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

专有数据飞轮

讨论真实反馈、数据权利、质量过滤与持续改进形成的壁垒。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

圣杯必须拆成能力定义、代理指标、资源预算和反证条件。若一个进展只能在封闭基准或无限预算下成立，它尚未跨越工程门槛。

- 决策：在采用“专有数据飞轮”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [专有数据飞轮](#)。

实时多模态接口

关注低延迟语音、视觉、文本和行动统一带来的新交互。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

圣杯必须拆成能力定义、代理指标、资源预算和反证条件。若一个进展只能在封闭基准或无限预算下成立，它尚未跨越工程门槛。

- 决策：在采用“实时多模态接口”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实时多模态接口](#)。

私有、个人与边缘智能

讨论本地推理、隐私、个性化和设备资源约束。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

圣杯必须拆成能力定义、代理指标、资源预算和反证条件。若一个进展只能在封闭基准或无限预算下成立，它尚未跨越工程门槛。

- 决策：在采用“私有、个人与边缘智能”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [私有、个人与边缘智能](#)。

生态与平台优势

分析模型、开发工具、分发渠道和标准接口的网络效应。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

圣杯必须拆成能力定义、代理指标、资源预算和反证条件。若一个进展只能在封闭基准或无限预算下成立，它尚未跨越工程门槛。

- 决策：在采用“生态与平台优势”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [生态与平台优势](#)。

安全、治理与信任

把合规、可审计性、事件响应和社会许可视为产品能力。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

圣杯必须拆成能力定义、代理指标、资源预算和反证条件。若一个进展只能在封闭基准或无限预算下成立，它尚未跨越工程门槛。

- 决策：在采用“安全、治理与信任”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [安全、治理与信任](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

04 成熟技术流派与公开案例

没有适用于所有任务的单一路线。稠密、MoE、推理优先、检索记忆、多模态、Agent 和小模型各自优化不同约束。

所谓技术流派，是一组可复用的架构、训练信号、推理预算与产品假设。比较时必须固定模型规模、数据、延迟和成本，避免用单一榜单把不同优化目标混为一谈。

技术流派比较矩阵

用能力、数据、训练成本、推理成本、生态和风险进行同口径比较。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

流派比较要固定任务分布和服务约束。总参数、激活参数、训练 token、推理预算、上下文长度和外部工具都是系统变量，不能只比较模型名称。

- 决策：在采用“技术流派比较矩阵”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [技术流派比较矩阵](#)。

稠密 Decoder 通用模型

说明其简单稳定、生态成熟以及计算和内存线性增长的代价。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

流派比较要固定任务分布和服务约束。总参数、激活参数、训练 token、推理预算、上下文长度和外部工具都是系统变量，不能只比较模型名称。

- 决策：在采用“稠密 Decoder 通用模型”前，写出最便宜的基线 and 它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [稠密 Decoder 通用模型](#)。

稀疏 MoE

解释总参数、激活参数、路由、负载均衡和通信复杂度的权衡。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

流派比较要固定任务分布和服务约束。总参数、激活参数、训练 token、推理预算、上下文长度和外部工具都是系统变量，不能只比较模型名称。

- 决策：在采用“稀疏 MoE”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [稀疏 MoE](#)。

推理优先与测试时扩展

分析验证器强化学习、搜索和推理预算如何交换成本与正确率。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

流派比较要固定任务分布和服务约束。总参数、激活参数、训练 token、推理预算、上下文长度和外部工具都是系统变量，不能只比较模型名称。

- 决策：在采用“推理优先与测试时扩展”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [推理优先与测试时扩展](#)。

长上下文、RAG 与记忆

区分窗口容量、有效利用、外部检索和持久状态的职责。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

流派比较要固定任务分布和服务约束。总参数、激活参数、训练 token、推理预算、上下文长度和外部工具都是系统变量，不能只比较模型名称。

- 决策：在采用“长上下文、RAG 与记忆”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [长上下文、RAG 与记忆](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

原生多模态

比较组合式编码器与统一 token/统一模型路线。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

流派比较要固定任务分布和服务约束。总参数、激活参数、训练 token、推理预算、上下文长度和外部工具都是系统变量，不能只比较模型名称。

- 决策：在采用“原生多模态”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [原生多模态](#)。

Agentic System

把模型嵌入工具、环境、验证和恢复循环形成系统能力。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

流派比较要固定任务分布和服务约束。总参数、激活参数、训练 token、推理预算、上下文长度和外部工具都是系统变量，不能只比较模型名称。

- 决策：在采用“Agentic System”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。

- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [Agentic System](#)。

小模型与边缘模型

讨论蒸馏、量化、专门化和设备协同带来的成本优势。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

流派比较要固定任务分布和服务约束。总参数、激活参数、训练 token、推理预算、上下文长度和外部工具都是系统变量，不能只比较模型名称。

- 决策：在采用“小模型与边缘模型”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [小模型与边缘模型](#)。

开放模型全栈

评估公开权重、数据、代码、日志和许可证的不同开放层级。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

流派比较要固定任务分布和服务约束。总参数、激活参数、训练 token、推理预算、上下文长度和外部工具都是系统变量，不能只比较模型名称。

- 决策：在采用“开放模型全栈”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [开放模型全栈](#)。

Llama 系列案例

用公开报告拆解稠密模型、数据规模、后训练和安全发布。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

流派比较要固定任务分布和服务约束。总参数、激活参数、训练 token、推理预算、上下文长度和外部工具都是系统变量，不能只比较模型名称。

- 决策：在采用“Llama 系列案例”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。

- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [Llama 系列案例](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

Qwen 系列案例

分析多语言、稠密与 MoE、思考模式和开放模型实践。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

流派比较要固定任务分布和服务约束。总参数、激活参数、训练 token、推理预算、上下文长度和外部工具都是系统变量，不能只比较模型名称。

- 决策：在采用“Qwen 系列案例”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [Qwen 系列案例](#)。

DeepSeek 系列案例

分析 MLA、MoE、低精度训练和可验证推理路线。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

流派比较要固定任务分布和服务约束。总参数、激活参数、训练 token、推理预算、上下文长度和外部工具都是系统变量，不能只比较模型名称。

- 决策：在采用“DeepSeek 系列案例”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [DeepSeek 系列案例](#)。

OLMo 系列案例

分析数据、代码、检查点和训练日志的开放科学价值。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

流派比较要固定任务分布和服务约束。总参数、激活参数、训练 token、推理预算、上下文长度和外部工具都是系统变量，不能只比较模型名称。

- 决策：在采用“OLMo 系列案例”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [OLMo 系列案例](#)。

Mistral 系列案例

分析小型稠密模型、滑动窗口与 MoE 的工程取舍。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

流派比较要固定任务分布和服务约束。总参数、激活参数、训练 token、推理预算、上下文长度和外部工具都是系统变量，不能只比较模型名称。

- 决策：在采用“Mistral 系列案例”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [Mistral 系列案例](#)。

05 目标、数据与 Tokenizer

训练在第一块 GPU 启动之前就已被目标、评测、数据权利和表示方式决定。

Top 模型工程是一条有反馈、有门禁、可回滚的流水线。上游的目标与数据选择会改变下游所有结论；评测、安全性和经济性必须在训练前定义，而不是发布前补做。

能力契约

在训练前定义用户、任务分布、成功、拒答、风险和资源边界。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

能力契约先规定成功与不可接受失败，再倒推评测、数据和预算。没有发布门槛的目标会在训练中不断漂移。

- 决策：在采用“能力契约”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [能力契约](#)。

目标评测套件

把能力、安全、稳健性、延迟和成本构造成发布门禁。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

能力契约先规定成功与不可接受失败，再倒推评测、数据和预算。没有发布门槛的目标会在训练中不断漂移。

- 决策：在采用“目标评测套件”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [目标评测套件](#)。

规模计划与预算

由目标损失、数据供给、训练 FLOPs、集群效率和推理生命周期反推规模。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

能力契约先规定成功与不可接受失败，再倒推评测、数据和预算。没有发布门槛的目标会在训练中不断漂移。

- 决策：在采用“规模计划与预算”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [规模计划与预算](#)。

数据来源、许可与治理

建立来源、用途、权利、保留期和删除请求的可追溯链。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

数据工程的单位不是文件，而是带来源、许可、转换、质量和用途的样本。任何过滤都会改变分布，任何混合都隐含能力优先级。

- 决策：在采用“数据来源、许可与治理”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [数据来源、许可与治理](#)。

采集与解析

处理网页、代码、论文和多媒体采集中的结构、编码与失败恢复。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

数据工程的单位不是文件，而是带来源、许可、转换、质量和用途的样本。任何过滤都会改变分布，任何混合都隐含能力优先级。

- 决策：在采用“采集与解析”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [采集与解析](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

清洗、去重与质量

比较规则、模型过滤、近似去重和质量评分对能力与多样性的影响。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

数据工程的单位不是文件，而是带来源、许可、转换、质量和用途的样本。任何过滤都会改变分布，任何混合都隐含能力优先级。

- 决策：在采用“清洗、去重与质量”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [清洗、去重与质量](#)。

数据混合、采样与课程

把能力目标转为数据权重、温度、阶段和反馈调节策略。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

数据工程的单位不是文件，而是带来源、许可、转换、质量和用途的样本。任何过滤都会改变分布，任何混合都隐含能力优先级。

- 决策：在采用“数据混合、采样与课程”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [数据混合、采样与课程](#)。

合成数据

区分扩充、蒸馏、难例生成和验证数据，并控制模型坍塌风险。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

数据工程的单位不是文件，而是带来源、许可、转换、质量和用途的样本。任何过滤都会改变分布，任何混合都隐含能力优先级。

- 决策：在采用“合成数据”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [合成数据](#)。

污染与泄漏

识别预训练、后训练、检索和评审器对评测数据的直接或间接泄漏。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

数据工程的单位不是文件，而是带来源、许可、转换、质量和用途的样本。任何过滤都会改变分布，任何混合都隐含能力优先级。

- 决策：在采用“污染与泄漏”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [污染与泄漏](#)。

数据基础设施

设计不可变分片、版本、血缘、质量指标和可恢复的数据流水线。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

数据工程的单位不是文件，而是带来源、许可、转换、质量和用途的样本。任何过滤都会改变分布，任何混合都隐含能力优先级。

- 决策：在采用“数据基础设施”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [数据基础设施](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

BPE、Unigram 与字节模型

比较压缩率、词表、未知字符、训练成本和推理长度。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

Tokenizer 同时影响训练长度、语言公平、数字与代码表示以及推理成本。词表选择必须用目标语料的压缩率和下游任务共同评估。

- 决策：在采用“BPE、Unigram 与字节模型”前，写出最便宜的基线 and 它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [BPE、Unigram 与字节模型](#)。

多语言、代码与数字

评估不同字符系统、空白、标识符和数值表示的公平性。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

Tokenizer 同时影响训练长度、语言公平、数字与代码表示以及推理成本。词表选择必须用目标语料的压缩率和下游任务共同评估。

- 决策：在采用“多语言、代码与数字”前，写出最便宜的基线 and 它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [多语言、代码与数字](#)。

Tokenizer 评测

用压缩率、回退率、边界稳定性和任务表现选择词表。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

Tokenizer 同时影响训练长度、语言公平、数字与代码表示以及推理成本。词表选择必须用目标语料的压缩率和下游任务共同评估。

- 决策：在采用“Tokenizer 评测”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [Tokenizer 评测](#)。

06 架构与训练系统

架构决定计算图，训练系统决定它能否以可接受效率和故障率运行。二者必须协同设计。

Top 模型工程是一条有反馈、有门禁、可回滚的流水线。上游的目标与数据选择会改变下游所有结论；评测、安全性和经济性必须在训练前定义，而不是发布前补做。

Decoder-only Transformer

从张量形状、残差流和因果目标解释现代语言模型主干。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

架构决策最终落到张量形状、访存、通信和可训练性。理论复杂度较低不等于硬件更快，支持长窗口也不等于能可靠使用。

- 决策：在采用“Decoder-only Transformer”前，写出最便宜的基线 and 它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [Decoder-only Transformer](#)。

注意力与 KV Cache

连接训练时注意力、推理缓存、带宽和长上下文成本。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

架构决策最终落到张量形状、访存、通信和可训练性。理论复杂度较低不等于硬件更快，支持长窗口也不等于能可靠使用。

- 决策：在采用“注意力与 KV Cache”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [注意力与 KV Cache](#)。

位置、归一化与激活

比较 RoPE、RMSNorm、SwiGLU 等组件对稳定性与外推的影响。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

架构决策最终落到张量形状、访存、通信和可训练性。理论复杂度较低不等于硬件更快，支持长窗口也不等于能可靠使用。

- 决策：在采用“位置、归一化与激活”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [位置、归一化与激活](#)。

Mixture of Experts

解释专家路由、容量、负载均衡、专家并行和推理部署。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

架构决策最终落到张量形状、访存、通信和可训练性。理论复杂度较低不等于硬件更快，支持长窗口也不等于能可靠使用。

- 决策：在采用“Mixture of Experts”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [Mixture of Experts](#)。

长上下文架构

区分位置外推、稀疏注意力、上下文并行和真实检索能力。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

架构决策最终落到张量形状、访存、通信和可训练性。理论复杂度较低不等于硬件更快，支持长窗口也不等于能可靠使用。

- 决策：在采用“长上下文架构”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [长上下文架构](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

多模态架构

比较适配器、交叉注意力、统一表示和多模态生成头。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

架构决策最终落到张量形状、访存、通信和可训练性。理论复杂度较低不等于硬件更快，支持长窗口也不等于能可靠使用。

- 决策：在采用“多模态架构”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [多模态架构](#)。

状态空间与混合模型

讨论线性序列建模、选择性状态和注意力混合的边界。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

架构决策最终落到张量形状、访存、通信和可训练性。理论复杂度较低不等于硬件更快，支持长窗口也不等于能可靠使用。

- 决策：在采用“状态空间与混合模型”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [状态空间与混合模型](#)。

加速器、网络与存储

从 HBM、互连、集合通信和检查点带宽理解集群瓶颈。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

训练系统要把计算、内存、网络、存储和故障概率组成一张账。扩容前先测量每层时间和通信，否则更多 GPU 可能只放大等待。

- 决策：在采用“加速器、网络与存储”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [加速器、网络与存储](#)。

五类并行策略

组合数据、张量、流水线、上下文和专家并行并计算通信代价。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

训练系统要把计算、内存、网络、存储和故障概率组成一张账。扩容前先测量每层时间和通信，否则更多 GPU 可能只放大等待。

- 决策：在采用“五类并行策略”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [五类并行策略](#)。

精度、显存与优化器状态

拆解参数、梯度、激活、主权重和优化器状态的显存账本。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

训练系统要把计算、内存、网络、存储和故障概率组成一张账。扩容前先测量每层时间和通信，否则更多 GPU 可能只放大等待。

- 决策：在采用“精度、显存与优化器状态”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [精度、显存与优化器状态](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

内核、编译器与通信

分析算子融合、重计算、通信重叠和形状专门化。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

训练系统要把计算、内存、网络、存储和故障概率组成一张账。扩容前先测量每层时间和通信，否则更多 GPU 可能只放大等待。

- 决策：在采用“内核、编译器与通信”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [内核、编译器与通信](#)。

检查点与容错

设计分片检查点、异步落盘、健康检测和确定性恢复。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

训练系统要把计算、内存、网络、存储和故障概率组成一张账。扩容前先测量每层时间和通信，否则更多 GPU 可能只放大等待。

- 决策：在采用“检查点与容错”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [检查点与容错](#)。

训练遥测与容量规划

用吞吐、MFU、气泡、网络 and 异常指标定位损失。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

训练系统要把计算、内存、网络、存储和故障概率组成一张账。扩容前先测量每层时间和通信，否则更多 GPU 可能只放大等待。

- 决策：在采用“训练遥测与容量规划”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [训练遥测与容量规划](#)。

07 预训练与能力塑形

预训练学习广泛分布，Mid-training 通过领域、长度和课程塑造后续可对齐能力。

Top 模型工程是一条有反馈、有门禁、可回滚的流水线。上游的目标与数据选择会改变下游所有结论；评测、安全性和经济性必须在训练前定义，而不是发布前补做。

预训练目标与损失

解释 next-token 目标、掩码、长度归一化和辅助损失。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

预训练的核心是稳定地消费正确数据并持续产生可解释损失。损失下降、验证能力、吞吐和数据质量需要同屏观察。

- 决策：在采用“预训练目标与损失”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [预训练目标与损失](#)。

优化器、学习率与批量

连接 AdamW、warmup、衰减、梯度噪声和全局批量。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

预训练的核心是稳定地消费正确数据并持续产生可解释损失。损失下降、验证能力、吞吐和数据质量需要同屏观察。

- 决策：在采用“优化器、学习率与批量”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [优化器、学习率与批量](#)。

Scaling Pilot

通过小规模实验拟合数据、参数、计算和质量的关系。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

预训练的核心是稳定地消费正确数据并持续产生可解释损失。损失下降、验证能力、吞吐和数据质量需要同屏观察。

- 决策：在采用“Scaling Pilot”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [Scaling Pilot](#)。

稳定性与故障诊断

处理损失尖峰、溢出、坏批次、通信异常和数据漂移。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

预训练的核心是稳定地消费正确数据并持续产生可解释损失。损失下降、验证能力、吞吐和数据质量需要同屏观察。

- 决策：在采用“稳定性与故障诊断”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [稳定性与故障诊断](#)。

预训练运行手册

给出启动、观测、暂停、回滚、验收和交接的控制流程。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

预训练的核心是稳定地消费正确数据并持续产生可解释损失。损失下降、验证能力、吞吐和数据质量需要同屏观察。

- 决策：在采用“预训练运行手册”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [预训练运行手册](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

持续预训练

在保持通用能力的同时吸收新领域知识和分布。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

Mid-training 用领域、长度和能力课程重新塑造基础模型分布。必须加入通用数据回放并分别测量学习与遗忘。

- 决策：在采用“持续预训练”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。

- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [持续预训练](#)。

领域与代码适配

设计领域数据、代码执行反馈和通用能力回放。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

Mid-training 用领域、长度和能力课程重新塑造基础模型分布。必须加入通用数据回放并分别测量学习与遗忘。

- 决策：在采用“领域与代码适配”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [领域与代码适配](#)。

长上下文扩展

联合调整位置编码、长度课程、内存与评测。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

Mid-training 用领域、长度和能力课程重新塑造基础模型分布。必须加入通用数据回放并分别测量学习与遗忘。

- 决策：在采用“长上下文扩展”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [长上下文扩展](#)。

能力塑形

用数据阶段和目标函数在后训练前建立数学、代码、工具等先验。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

Mid-training 用领域、长度和能力课程重新塑造基础模型分布。必须加入通用数据回放并分别测量学习与遗忘。

- 决策：在采用“能力塑形”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [能力塑形](#)。

08 后训练、推理与自我改进

后训练不是润色，它决定模型如何分配推理、遵循偏好、调用工具和表达不确定性。

Top 模型工程是一条有反馈、有门禁、可回滚的流水线。上游的目标与数据选择会改变下游所有结论；评测、安全性和经济性必须在训练前定义，而不是发布前补做。

后训练数据

设计指令、偏好、拒答、工具和多轮轨迹的数据体系。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

后训练优化的是序列行为而非单纯知识量。模板、标注偏好、拒答和奖励都可能形成捷径，需要独立能力与安全回归。

- 决策：在采用“后训练数据”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [后训练数据](#)。

监督微调

控制模板、损失掩码、数据比例、过拟合和能力遗忘。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

后训练优化的是序列行为而非单纯知识量。模板、标注偏好、拒答和奖励都可能形成捷径，需要独立能力与安全回归。

- 决策：在采用“监督微调”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [监督微调](#)。

偏好与奖励建模

从成对比较、标注一致性和奖励校准建立行为信号。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

后训练优化的是序列行为而非单纯知识量。模板、标注偏好、拒答和奖励都可能形成捷径，需要独立能力与安全回归。

- 决策：在采用“偏好与奖励建模”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [偏好与奖励建模](#)。

DPO 与离线偏好优化

解释参考策略、偏好间隔、beta 和离线数据偏差。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

后训练优化的是序列行为而非单纯知识量。模板、标注偏好、拒答和奖励都可能形成捷径，需要独立能力与安全回归。

- 决策：在采用“DPO 与离线偏好优化”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [DPO 与离线偏好优化](#)。

在线强化学习

讨论采样、奖励、优势估计、约束和训练稳定性。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

后训练优化的是序列行为而非单纯知识量。模板、标注偏好、拒答和奖励都可能形成捷径，需要独立能力与安全回归。

- 决策：在采用“在线强化学习”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [在线强化学习](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

RLAIF 与安全训练

利用模型反馈与规则扩展监督，同时防止评审器偏差自我放大。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

后训练优化的是序列行为而非单纯知识量。模板、标注偏好、拒答和奖励都可能形成捷径，需要独立能力与安全回归。

- 决策：在采用“RLAIF 与安全训练”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [RLAIF 与安全训练](#)。

思维链与测试时计算

区分可见推理文本、内部计算、采样数量和推理预算。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

推理能力由策略、预算、搜索空间和验证信号共同决定。更长输出不是充分证据，必须区分正确推理、冗长和奖励投机。

- 决策：在采用“思维链与测试时计算”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [思维链与测试时计算](#)。

验证器与过程奖励

比较结果验证、步骤验证、形式执行和模型评审。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

推理能力由策略、预算、搜索空间和验证信号共同决定。更长输出不是充分证据，必须区分正确推理、冗长和奖励投机。

- 决策：在采用“验证器与过程奖励”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [验证器与过程奖励](#)。

GRPO 与可验证强化学习

分析组内相对优势、奖励稀疏和可验证任务课程。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

推理能力由策略、预算、搜索空间和验证信号共同决定。更长输出不是充分证据，必须区分正确推理、冗长和奖励投机。

- 决策：在采用“GRPO 与可验证强化学习”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [GRPO 与可验证强化学习](#)。

搜索、规划与反思

组合候选生成、树搜索、工具状态和失败恢复。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

推理能力由策略、预算、搜索空间和验证信号共同决定。更长输出不是充分证据，必须区分正确推理、冗长和奖励投机。

- 决策：在采用“搜索、规划与反思”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [搜索、规划与反思](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

推理蒸馏

把高预算轨迹压缩到小模型，同时控制错误推理复制。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

推理能力由策略、预算、搜索空间和验证信号共同决定。更长输出不是充分证据，必须区分正确推理、冗长和奖励投机。

- 决策：在采用“推理蒸馏”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [推理蒸馏](#)。

09 评测、压缩、推理服务与发布

只有被独立评测、成本化、可部署且可回滚的能力，才是工程上可使用的能力。

Top 模型工程是一条有反馈、有门禁、可回滚的流水线。上游的目标与数据选择会改变下游所有结论；评测、安全性和经济性必须在训练前定义，而不是发布前补做。

评测系统设计

从能力契约生成离线、在线、回归和发布门禁。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

评测是发布控制面，不是最终宣传表。测试集隔离、方差、失败严重程度、评审器校准和线上漂移共同决定可信度。

- 决策：在采用“评测系统设计”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [评测系统设计](#)。

基准与统计

处理样本量、置信区间、方差、显著性和多重比较。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

评测是发布控制面，不是最终宣传表。测试集隔离、方差、失败严重程度、评审器校准和线上漂移共同决定可信度。

- 决策：在采用“基准与统计”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [基准与统计](#)。

人工与模型评审

校准偏好、位置、长度、风格和同源模型偏差。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

评测是发布控制面，不是最终宣传表。测试集隔离、方差、失败严重程度、评审器校准和线上漂移共同决定可信度。

- 决策：在采用“人工与模型评审”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。

- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [人工与模型评审](#)。

污染与刷榜

检测训练泄漏、模板记忆、提示敏感和指标投机。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

评测是发布控制面，不是最终宣传表。测试集隔离、方差、失败严重程度、评审器校准和线上漂移共同决定可信度。

- 决策：在采用“污染与刷榜”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [污染与刷榜](#)。

安全、对齐与红队

覆盖滥用、越狱、隐私、偏见、失控和事件演练。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

评测是发布控制面，不是最终宣传表。测试集隔离、方差、失败严重程度、评审器校准和线上漂移共同决定可信度。

- 决策：在采用“安全、对齐与红队”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [安全、对齐与红队](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

Agent 与真实任务评测

测量长任务成功、恢复、权限、成本和环境变化。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

评测是发布控制面，不是最终宣传表。测试集隔离、方差、失败严重程度、评审器校准和线上漂移共同决定可信度。

- 决策：在采用“Agent 与真实任务评测”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [Agent 与真实任务评测](#)。

蒸馏

比较 logits、特征、偏好和推理轨迹蒸馏。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

压缩与适配要比较任务成功一次的总成本。文件更小不代表运行更快，离线误差更低也不保证目标硬件收益。

- 决策：在采用“蒸馏”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [蒸馏](#)。

量化

解释权重、激活、KV 缓存精度与校准数据。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

压缩与适配要比较任务成功一次的总成本。文件更小不代表运行更快，离线误差更低也不保证目标硬件收益。

- 决策：在采用“量化”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。

- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [量化](#)。

剪枝与稀疏

区分非结构化、结构化和动态稀疏的真实加速条件。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

压缩与适配要比较任务成功一次的总成本。文件更小不代表运行更快，离线误差更低也不保证目标硬件收益。

- 决策：在采用“剪枝与稀疏”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [剪枝与稀疏](#)。

模型合并与 Adapter

管理多任务 LoRA、权重合并、冲突和回滚。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

压缩与适配要比较任务成功一次的总成本。文件更小不代表运行更快，离线误差更低也不保证目标硬件收益。

- 决策：在采用“模型合并与 Adapter”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [模型合并与 Adapter](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

解码

比较贪心、采样、束搜索、约束解码和停止条件。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

在线推理是带队列和共享内存的调度系统。首 token、每 token、尾延迟、吞吐、KV 占用和取消行为必须联合测量。

- 决策：在采用“解码”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [解码](#)。

推理引擎

拆解模型加载、调度、内核、流式输出和分布式执行。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

在线推理是带队列和共享内存的调度系统。首 token、每 token、尾延迟、吞吐、KV 占用和取消行为必须联合测量。

- 决策：在采用“推理引擎”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [推理引擎](#)。

连续批处理与分页 KV

解释动态到达、显存碎片和 KV 生命周期管理。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

在线推理是带队列和共享内存的调度系统。首 token、每 token、尾延迟、吞吐、KV 占用和取消行为必须联合测量。

- 决策：在采用“连续批处理与分页 KV”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [连续批处理与分页 KV](#)。

推测解码

通过草稿模型和验证器减少串行解码步。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

在线推理是带队列和共享内存的调度系统。首 token、每 token、尾延迟、吞吐、KV 占用和取消行为必须联合测量。

- 决策：在采用“推测解码”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [推测解码](#)。

并行推理

比较张量、流水线、专家和数据副本在在线服务中的组合。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

在线推理是带队列和共享内存的调度系统。首 token、每 token、尾延迟、吞吐、KV 占用和取消行为必须联合测量。

- 决策：在采用“并行推理”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [并行推理](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

路由、时延、吞吐与成本

以任务成功一次的总成本决定模型和预算路由。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

在线推理是带队列和共享内存的调度系统。首 token、每 token、尾延迟、吞吐、KV 占用和取消行为必须联合测量。

- 决策：在采用“路由、时延、吞吐与成本”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。

- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [路由、时延、吞吐与成本](#)。

模型卡与发布门禁

把训练信息、能力、限制和责任转为可审计发布材料。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

发布不是交付终点。版本身份、灰度、监控、反馈权利、事故响应和退役标准共同形成可运营生命周期。

- 决策：在采用“模型卡与发布门禁”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [模型卡与发布门禁](#)。

分阶段部署

设计离线、影子、灰度、地域和租户级发布。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

发布不是交付终点。版本身份、灰度、监控、反馈权利、事故响应和退役标准共同形成可运营生命周期。

- 决策：在采用“分阶段部署”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [分阶段部署](#)。

监控与反馈

连接质量、漂移、安全、成本、用户反馈和数据回流。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

发布不是交付终点。版本身份、灰度、监控、反馈权利、事故响应和退役标准共同形成可运营生命周期。

- 决策：在采用“监控与反馈”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [监控与反馈](#)。

版本与可复现

统一权重、代码、配置、数据和评测的版本身份。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

发布不是交付终点。版本身份、灰度、监控、反馈权利、事故响应和退役标准共同形成可运营生命周期。

- 决策：在采用“版本与可复现”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [版本与可复现](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

事件响应

定义检测、隔离、降级、取证、沟通和复盘。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

发布不是交付终点。版本身份、灰度、监控、反馈权利、事故响应和退役标准共同形成可运营生命周期。

- 决策：在采用“事件响应”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [事件响应](#)。

更新、蒸馏与退役

判断继续训练、重新训练、蒸馏、路由或退役的经济与风险门槛。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

发布不是交付终点。版本身份、灰度、监控、反馈权利、事故响应和退役标准共同形成可运营生命周期。

- 决策：在采用“更新、蒸馏与退役”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [更新、蒸馏与退役](#)。

10 上下文、RAG、记忆与 Agent

权重提供先验，系统通过动态知识、工具、状态和权限把先验连接到现实。

系统智能来自模型、上下文、检索、工具、状态、权限和验证器的组合。确定性逻辑应由程序执行，概率性判断交给模型，并为不可逆动作设置显式边界。

提示与上下文工程

把指令、示例、状态和约束组织成有限上下文预算。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

系统层通过上下文、知识、工具和状态弥补权重局限，也引入提示注入、权限升级和长任务误差累积。先用固定工作流，再为真正不确定的步骤开放规划。

- 决策：在采用“提示与上下文工程”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [提示与上下文工程](#)。

检索、重排与 RAG

设计查询、召回、重排、上下文拼装、引用和忠实度评测。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

系统层通过上下文、知识、工具和状态弥补权重局限，也引入提示注入、权限升级和长任务误差累积。先用固定工作流，再为真正不确定的步骤开放规划。

- 决策：在采用“检索、重排与 RAG”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [检索、重排与 RAG](#)。

知识图谱与事实落地

在实体关系、文档证据和生成答案之间建立可追溯连接。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

系统层通过上下文、知识、工具和状态弥补权重局限，也引入提示注入、权限升级和长任务误差累积。先用固定工作流，再为真正不确定的步骤开放规划。

- 决策：在采用“知识图谱与事实落地”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [知识图谱与事实落地](#)。

工作、情景与语义记忆

按时间尺度、所有权、写入门槛和遗忘策略设计记忆。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

系统层通过上下文、知识、工具和状态弥补权重局限，也引入提示注入、权限升级和长任务误差累积。先用固定 workflow，再为真正不确定的步骤开放规划。

- 决策：在采用“工作、情景与语义记忆”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [工作、情景与语义记忆](#)。

工具调用与协议

定义工具 schema、错误语义、幂等、超时、认证和协议互操作。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

系统层通过上下文、知识、工具和状态弥补权重局限，也引入提示注入、权限升级和长任务误差累积。先用固定工作流，再为真正不确定的步骤开放规划。

- 决策：在采用“工具调用与协议”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [工具调用与协议](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

工作流与 Agent

根据任务确定性、状态空间和风险选择固定编排或动态规划。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

系统层通过上下文、知识、工具和状态弥补权重局限，也引入提示注入、权限升级和长任务误差累积。先用固定工作流，再为真正不确定的步骤开放规划。

- 决策：在采用“工作流与 Agent”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [工作流与 Agent](#)。

规划、反思与验证

用计划、执行、观察、校验和重规划组成受控循环。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

系统层通过上下文、知识、工具和状态弥补权重局限，也引入提示注入、权限升级和长任务误差累积。先用固定工作流，再为真正不确定的步骤开放规划。

- 决策：在采用“规划、反思与验证”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [规划、反思与验证](#)。

多 Agent 系统

分析角色分工、共享状态、通信开销和错误相关性。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

系统层通过上下文、知识、工具和状态弥补权重局限，也引入提示注入、权限升级和长任务误差累积。先用固定工作流，再为真正不确定的步骤开放规划。

- 决策：在采用“多 Agent 系统”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [多 Agent 系统](#)。

编码与计算机使用

将仓库、终端、浏览器和 GUI 转为可观测、可回滚的行动空间。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

系统层通过上下文、知识、工具和状态弥补权重局限，也引入提示注入、权限升级和长任务误差累积。先用固定工作流，再为真正不确定的步骤开放规划。

- 决策：在采用“编码与计算机使用”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [编码与计算机使用](#)。

实时多模态系统

协调音视频采集、编解码、流式推理、中断和延迟预算。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

系统层通过上下文、知识、工具和状态弥补权重局限，也引入提示注入、权限升级和长任务误差累积。先用固定工作流，再为真正不确定的步骤开放规划。

- 决策：在采用“实时多模态系统”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实时多模态系统](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

Agent 评测与观测

记录轨迹、工具结果、状态转移、人工接管和单位成功成本。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

系统层通过上下文、知识、工具和状态弥补权重局限，也引入提示注入、权限升级和长任务误差累积。先用固定工作流，再为真正不确定的步骤开放规划。

- 决策：在采用“Agent 评测与观测”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [Agent 评测与观测](#)。

权限、沙箱与安全

以最小权限、能力令牌、隔离执行和审批门控制行动。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

系统层通过上下文、知识、工具和状态弥补权重局限，也引入提示注入、权限升级和长任务误差累积。先用固定工作流，再为真正不确定的步骤开放规划。

- 决策：在采用“权限、沙箱与安全”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [权限、沙箱与安全](#)。

11 小模型实践：从零训练到验证闭环

实践用两条轨道连接原理和工程：Atlas-125M 解释内部机制，Qwen3-0.6B 演练成熟后训练和服务链路。

实践以可复现和可解释为第一目标。每次实验固定代码、配置、数据清单和随机种子，先跑 CPU 小样，再进入单卡训练；任何提升都要用独立测试集和成本指标验证。

实践学习成果

定义每个实验应能解释、运行、测量和排障的能力。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实践学习成果”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实践学习成果](#)。

算力、成本与硬件

给出 CPU、小样、24GB 单卡和 8 卡配置的时间与显存账本。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“算力、成本与硬件”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [算力、成本与硬件](#)。

实验纪律

固定种子、数据、配置、环境、基线和回归门槛。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实验纪律”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实验纪律](#)。

实验 00：环境与基线

安装依赖、运行 CPU 烟雾测试并记录未训练基线。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实验 00：环境与基线”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实验 00：环境与基线](#)。

实验 01：数据与 Tokenizer

构造许可清晰的数据样本，训练词表并测量压缩率。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实验 01：数据与 Tokenizer”前，写出最便宜的基线和他无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实验 01：数据与 Tokenizer](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

实验 02：从零实现 Transformer

实现嵌入、RoPE、因果注意力、MLP、残差和语言模型头。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实验 02：从零实现 Transformer”前，写出最便宜的基线和他无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实验 02：从零实现 Transformer](#)。

实验 03：预训练 Atlas-125M

在单卡运行缩放后的预训练并观察损失、吞吐和生成样本。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实验 03：预训练 Atlas-125M”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实验 03：预训练 Atlas-125M](#)。

实验 04：持续预训练 Qwen3-0.6B

用领域数据适配公开基础模型并防止通用能力遗忘。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实验 04：持续预训练 Qwen3-0.6B”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实验 04：持续预训练 Qwen3-0.6B](#)。

实验 05：SFT 与 LoRA

构造聊天模板、损失掩码和高质量指令数据。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实验 05：SFT 与 LoRA”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实验 05：SFT 与 LoRA](#)。

实验 06：偏好优化

训练 DPO 配置并比较帮助性、格式和能力退化。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实验 06：偏好优化”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实验 06：偏好优化](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

实验 07：可验证强化学习

在算术和程序任务上用执行器奖励开展小规模策略优化。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实验 07：可验证强化学习”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实验 07：可验证强化学习](#)。

实验 08：合成数据课程

生成、去重、验证并按难度组织训练样本。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实验 08：合成数据课程”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实验 08：合成数据课程](#)。

实验 09：自进化闭环

运行生成、验证、回放、再训练和独立回归评测循环。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实验 09：自进化闭环”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实验 09：自进化闭环](#)。

实验 10：评测与回归

建立能力、安全、格式、延迟和成本的版本比较。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实验 10：评测与回归”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实验 10：评测与回归](#)。

实验 11：量化与 vLLM 服务

导出、量化并通过兼容 API 服务模型。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实验 11：量化与 vLLM 服务”前，写出最便宜的基线 and 它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实验 11：量化与 vLLM 服务](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

实验 12：RAG 与 Agent 应用

为模型增加检索、工具、权限和轨迹评测。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实验 12：RAG 与 Agent 应用”前，写出最便宜的基线 and 它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实验 12：RAG 与 Agent 应用](#)。

实验 13：从单卡到八卡

将单卡配置映射到 FSDP、张量并行和集群检查点。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实验 13：从单卡到八卡”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实验 13：从单卡到八卡](#)。

实验结果与边界

区分演示成功、统计提升、分布外失败和不可外推结论。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

实验先跑最小规模证明正确性，再扩大 token、模型和设备。配置、数据清单、种子、环境和保留集是结果的一部分。

- 决策：在采用“实验结果与边界”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [实验结果与边界](#)。

12 生产工程与 2026-10 状态

生产成熟度由失败恢复、权限、尾延迟、成本和事故能力决定；现状必须按日期和证据等级记录。

生产系统关注尾延迟、失败恢复、权限、审计和单位任务成本，而非离线演示。模型只是依赖之一，必须通过网关、策略、观测和降级机制纳入既有工程治理。

生产参考架构

划分客户端、网关、编排、模型、知识、工具、策略和观测平面。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

生产链路按控制面与数据面分离，所有外部依赖都要有超时、重试上限、幂等、降级和审计。平均质量不能抵消严重安全失败。

- 决策：在采用“生产参考架构”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [生产参考架构](#)。

前端 AI 体验

处理流式输出、中断、可编辑状态、引用、错误和人机协作。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

生产链路按控制面与数据面分离，所有外部依赖都要有超时、重试上限、幂等、降级和审计。平均质量不能抵消严重安全失败。

- 决策：在采用“前端 AI 体验”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [前端 AI 体验](#)。

后端编排与流式协议

设计 SSE/WebSocket、任务状态、背压、重试和幂等。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

生产链路按控制面与数据面分离，所有外部依赖都要有超时、重试上限、幂等、降级和审计。平均质量不能抵消严重安全失败。

- 决策：在采用“后端编排与流式协议”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [后端编排与流式协议](#)。

模型网关、路由与回退

统一供应商协议并按质量、成本、区域和错误类型路由。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

生产链路按控制面与数据面分离，所有外部依赖都要有超时、重试上限、幂等、降级和审计。平均质量不能抵消严重安全失败。

- 决策：在采用“模型网关、路由与回退”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [模型网关、路由与回退](#)。

控制平面与数据平面

分离配置、策略、部署与高吞吐请求执行。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

生产链路按控制面与数据面分离，所有外部依赖都要有超时、重试上限、幂等、降级和审计。平均质量不能抵消严重安全失败。

- 决策：在采用“控制平面与数据平面”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [控制平面与数据平面](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

身份、权限与多租户

传播用户身份、租户边界、配额和审计上下文。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

生产链路按控制面与数据面分离，所有外部依赖都要有超时、重试上限、幂等、降级和审计。平均质量不能抵消严重安全失败。

- 决策：在采用“身份、权限与多租户”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。

- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [身份、权限与多租户](#)。

LLMOps、EvalOps 与观测

把提示、模型、数据、轨迹、质量和成本纳入版本化运营。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

生产链路按控制面与数据面分离，所有外部依赖都要有超时、重试上限、幂等、降级和审计。平均质量不能抵消严重安全失败。

- 决策：在采用“LLMOps、EvalOps 与观测”前，写出最便宜的基线 and 它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [LLMOps、EvalOps 与观测](#)。

缓存、成本与容量

设计语义缓存、前缀缓存、配额和峰值容量。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

生产链路按控制面与数据面分离，所有外部依赖都要有超时、重试上限、幂等、降级和审计。平均质量不能抵消严重安全失败。

- 决策：在采用“缓存、成本与容量”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [缓存、成本与容量](#)。

安全工具执行

通过沙箱、超时、网络策略、密钥隔离和审批保护工具调用。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

生产链路按控制面与数据面分离，所有外部依赖都要有超时、重试上限、幂等、降级和审计。平均质量不能抵消严重安全失败。

- 决策：在采用“安全工具执行”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [安全工具执行](#)。

部署与渐进交付

使用影子、灰度、A/B、自动回滚和兼容检查。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

生产链路按控制面与数据面分离，所有外部依赖都要有超时、重试上限、幂等、降级和审计。平均质量不能抵消严重安全失败。

- 决策：在采用“部署与渐进交付”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [部署与渐进交付](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

事故与恢复

覆盖供应商故障、提示注入、数据泄漏、成本失控和模型退化。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

生产链路按控制面与数据面分离，所有外部依赖都要有超时、重试上限、幂等、降级和审计。平均质量不能抵消严重安全失败。

- 决策：在采用“事故与恢复”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [事故与恢复](#)。

现状快照方法

规定证据截止日、来源等级、成熟度刻度和更新方式。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

现状判断按研究演示、可重复实验、受控生产和大规模稳定运营分层。模型自报与独立证据分开，能力和可靠性分开。

- 决策：在采用“现状快照方法”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [现状快照方法](#)。

能力版图

按语言、代码、数学、知识、感知、工具和长任务描述锯齿边界。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

现状判断按研究演示、可重复实验、受控生产和大规模稳定运营分层。模型自报与独立证据分开，能力和可靠性分开。

- 决策：在采用“能力版图”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [能力版图](#)。

架构与训练雷达

追踪稠密、MoE、低精度、数据课程和训练系统的成熟度。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

现状判断按研究演示、可重复实验、受控生产和大规模稳定运营分层。模型自报与独立证据分开，能力和可靠性分开。

- 决策：在采用“架构与训练雷达”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [架构与训练雷达](#)。

后训练与推理雷达

追踪偏好优化、可验证强化学习、测试时计算和蒸馏。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

现状判断按研究演示、可重复实验、受控生产和大规模稳定运营分层。模型自报与独立证据分开，能力和可靠性分开。

- 决策：在采用“后训练与推理雷达”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [后训练与推理雷达](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

推理与成本雷达

比较缓存、批处理、推测解码、量化、路由和边缘部署。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

现状判断按研究演示、可重复实验、受控生产和大规模稳定运营分层。模型自报与独立证据分开，能力和可靠性分开。

- 决策：在采用“推理与成本雷达”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [推理与成本雷达](#)。

Agent 与软件工程

区分代码补全、仓库任务、计算机使用和长期自治的成熟度。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

现状判断按研究演示、可重复实验、受控生产和大规模稳定运营分层。模型自报与独立证据分开，能力和可靠性分开。

- 决策：在采用“Agent 与软件工程”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [Agent 与软件工程](#)。

多模态与具身系统

记录实时语音、视觉理解、生成和机器人闭环的证据。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

现状判断按研究演示、可重复实验、受控生产和大规模稳定运营分层。模型自报与独立证据分开，能力和可靠性分开。

- 决策：在采用“多模态与具身系统”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [多模态与具身系统](#)。

开放与闭源生态

按权重、代码、数据、日志、许可证和服务能力比较开放程度。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

现状判断按研究演示、可重复实验、受控生产和大规模稳定运营分层。
模型自报与独立证据分开，能力和可靠性分开。

- 决策：在采用“开放与闭源生态”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [开放与闭源生态](#)。

安全、监管与事件

跟踪能力评测、部署控制、事件公开和监管框架。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

现状判断按研究演示、可重复实验、受控生产和大规模稳定运营分层。
模型自报与独立证据分开，能力和可靠性分开。

- 决策：在采用“安全、监管与事件”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [安全、监管与事件](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

成熟度记分板

将研究演示、可重复实验、受控生产和大规模运营分层。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

现状判断按研究演示、可重复实验、受控生产和大规模稳定运营分层。模型自报与独立证据分开，能力和可靠性分开。

- 决策：在采用“成熟度记分板”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [成熟度记分板](#)。

13 职业迁移：研发到大模型专家

已有工程经验不是包袱。真正需要补足的是模型机制、实验方法、评测和数据—训练—服务之间的闭环。

转型目标不是收集术语，而是形成可交付能力：能拆解问题、建立评测、实现训练或系统链路、定位失败并解释成本。学习路线以作品和能力门槛推进。

能力矩阵

用理解、实现、测量、排障和架构五级刻度评估能力。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

成长以能否独立定义问题、建立基线、实现闭环、定位失败和解释成本为准。作品应留下配置、评测、事故和决策记录。

- 决策：在采用“能力矩阵”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [能力矩阵](#)。

共同基础

定义所有路线都需要的 Transformer、数据、评测、推理和安全基础。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

成长以能否独立定义问题、建立基线、实现闭环、定位失败和解释成本为准。作品应留下配置、评测、事故和决策记录。

- 决策：在采用“共同基础”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [共同基础](#)。

前端到 AI Engineer

利用交互、状态和性能经验进入多模态体验与 Agent 前端。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

成长以能否独立定义问题、建立基线、实现闭环、定位失败和解释成本为准。作品应留下配置、评测、事故和决策记录。

- 决策：在采用“前端到 AI Engineer”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [前端到 AI Engineer](#)。

后端到 LLM 平台工程师

利用 API、分布式和可靠性经验进入网关、编排和服务。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

成长以能否独立定义问题、建立基线、实现闭环、定位失败和解释成本为准。作品应留下配置、评测、事故和决策记录。

- 决策：在采用“后端到 LLM 平台工程师”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [后端到 LLM 平台工程师](#)。

数据平台到训练工程师

利用流水线、血缘和计算平台经验进入数据与分布式训练。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

成长以能否独立定义问题、建立基线、实现闭环、定位失败和解释成本为准。作品应留下配置、评测、事故和决策记录。

- 决策：在采用“数据平台到训练工程师”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [数据平台到训练工程师](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

模型与后训练专家

深入架构、优化、SFT、偏好与强化学习。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

成长以能否独立定义问题、建立基线、实现闭环、定位失败和解释成本为准。作品应留下配置、评测、事故和决策记录。

- 决策：在采用“模型与后训练专家”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。

- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [模型与后训练专家](#)。

推理与系统专家

深入内核、并行、调度、缓存和单位成本优化。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

成长以能否独立定义问题、建立基线、实现闭环、定位失败和解释成本为准。作品应留下配置、评测、事故和决策记录。

- 决策：在采用“推理与系统专家”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [推理与系统专家](#)。

Agent 与应用专家

深入上下文、工具、工作流、评测、权限与产品闭环。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

成长以能否独立定义问题、建立基线、实现闭环、定位失败和解释成本为准。作品应留下配置、评测、事故和决策记录。

- 决策：在采用“Agent 与应用专家”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [Agent 与应用专家](#)。

评测、安全与对齐专家

建立指标、红队、控制、治理和事件能力。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

成长以能否独立定义问题、建立基线、实现闭环、定位失败和解释成本为准。作品应留下配置、评测、事故和决策记录。

- 决策：在采用“评测、安全与对齐专家”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [评测、安全与对齐专家](#)。

30 天快速路线

用一个可部署作品建立全链路认知和术语最小集。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

成长以能否独立定义问题、建立基线、实现闭环、定位失败和解释成本为准。作品应留下配置、评测、事故和决策记录。

- 决策：在采用“30 天快速路线”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [30 天快速路线](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

12 周核心路线

完成从模型机制到训练、评测、RAG、Agent 和服务的主线。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

成长以能否独立定义问题、建立基线、实现闭环、定位失败和解释成本为准。作品应留下配置、评测、事故和决策记录。

- 决策：在采用“12 周核心路线”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [12 周核心路线](#)。

6 个月专家路线

通过专项研究、工业基准和技术写作建立专家深度。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

成长以能否独立定义问题、建立基线、实现闭环、定位失败和解释成本为准。作品应留下配置、评测、事故和决策记录。

- 决策：在采用“6 个月专家路线”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [6 个月专家路线](#)。

作品集项目

定义能证明训练、系统、评测和决策能力的项目证据。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

成长以能否独立定义问题、建立基线、实现闭环、定位失败和解释成本为准。作品应留下配置、评测、事故和决策记录。

- 决策：在采用“作品集项目”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [作品集项目](#)。

岗位与面试地图

按研究、训练、推理、平台、应用和安全岗位准备。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

成长以能否独立定义问题、建立基线、实现闭环、定位失败和解释成本为准。作品应留下配置、评测、事故和决策记录。

- 决策：在采用“岗位与面试地图”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [岗位与面试地图](#)。

不要先学什么

避免从框架 API、提示技巧、模型新闻和大而全数学开始。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

成长以能否独立定义问题、建立基线、实现闭环、定位失败和解释成本为准。作品应留下配置、评测、事故和决策记录。

- 决策：在采用“不要先学什么”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [不要先学什么](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

14 未来：情景、信号与不确定性

未来不是一条外推曲线。最有用的判断是明确情景、领先指标、资源约束和能够推翻判断的证据。

未来章节采用情景与证据等级，而非确定性预测。需要区分已经出现的早期信号、尚待规模验证的研究方向，以及依赖重大科学突破的长期假设。

当前范式之后的规模化

讨论数据、能耗和边际收益约束下的稀疏、模块化和算法进步。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

未来判断需要领先指标和反证条件。把近中期可验证趋势与依赖科学突破的远期假设分开，避免用情景替代事实。

- 决策：在采用“当前范式之后的规模化”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [当前范式之后的规模化](#)。

合成数据与自我改进

评估验证型闭环、模型坍塌、教师依赖和开放式自改进。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

未来判断需要领先指标和反证条件。把近中期可验证趋势与依赖科学突破的远期假设分开，避免用情景替代事实。

- 决策：在采用“合成数据与自我改进”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [合成数据与自我改进](#)。

持续学习与记忆

探索模型在不灾难遗忘的情况下更新知识和技能。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

未来判断需要领先指标和反证条件。把近中期可验证趋势与依赖科学突破的远期假设分开，避免用情景替代事实。

- 决策：在采用“持续学习与记忆”前，写出最便宜的基线和它无法满足的硬约束。

- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [持续学习与记忆](#)。

长时自治 Agent

研究错误累积、目标漂移、恢复和社会技术边界。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

未来判断需要领先指标和反证条件。把近中期可验证趋势与依赖科学突破的远期假设分开，避免用情景替代事实。

- 决策：在采用“长时自治 Agent”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [长时自治 Agent](#)。

世界模型与具身

连接多模态预测、模拟、规划、控制和真实反馈。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

未来判断需要领先指标和反证条件。把近中期可验证趋势与依赖科学突破的远期假设分开，避免用情景替代事实。

- 决策：在采用“世界模型与具身”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [世界模型与具身](#)。

阶段复盘

到这里应能画出本阶段的数据流与控制流，列出最可能的三个失败点，并说明下一项投入为什么比扩大模型更优先。

科学与工程智能

关注可执行实验、形式验证和人类专家协作。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

未来判断需要领先指标和反证条件。把近中期可验证趋势与依赖科学突破的远期假设分开，避免用情景替代事实。

- 决策：在采用“科学与工程智能”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [科学与工程智能](#)。

对齐、控制与治理

探索能力增长下的监督、隔离、审计和制度设计。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

未来判断需要领先指标和反证条件。把近中期可验证趋势与依赖科学突破的远期假设分开，避免用情景替代事实。

- 决策：在采用“对齐、控制与治理”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [对齐、控制与治理](#)。

硬件、能源与经济

分析算力供给、内存墙、网络、电力和成本结构。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

未来判断需要领先指标和反证条件。把近中期可验证趋势与依赖科学突破的远期假设分开，避免用情景替代事实。

- 决策：在采用“硬件、能源与经济”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。

- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [硬件、能源与经济](#)。

情景与不确定性

给出渐进增强、系统突破、平台集中和受限发展等情景。这要求把概念还原成目标、输入、计算、状态和输出，并明确何种证据能够支持结论。

未来判断需要领先指标和反证条件。把近中期可验证趋势与依赖科学突破的远期假设分开，避免用情景替代事实。

- 决策：在采用“情景与不确定性”前，写出最便宜的基线和它无法满足的硬约束。
- 观测：同时记录质量、失败样本、尾延迟、资源与单位成功成本，避免只看单一平均分。
- 边界：把无法公开验证或尚未实跑的部分标为假设；扩展材料见 [情景与不确定性](#)。

继续探索

github.com/fomos-openai/llm-atlas

仓库包含 205 篇知识正文、可运行小模型实验、结构化目录、证据登记与 Archify 交互地图。知识应该帮助工程师做出可解释、可验证、可回滚的决策。